

Eigenfaces:

Uma Análise Comparativa entre PCA e SVD

Beatriz Miranda

beatriz.bezerra@fgv.edu.br

Gustavo Murilo

gustavo.carvalho.2023@fgv.edu.br

Rio de Janeiro, Brasil

26 de novembro de 2023



Introdução

Uma possível aplicação das Eigenfaces

Rosto médio de mulheres de diferentes países



Resumidamente, as etapas para aplicação do PCA são:

1. Escolher variáveis (dimensões) a serem avaliadas;
2. Subtrair média de cada dimensão, produzindo um conjunto de dados com média zero;
3. Calcular matriz de covariância;
4. Calcular os autovetores e autovalores da matriz de covariância;
5. Escolher as k componentes principais (k autovetores com maior autovalor)
6. Interpretar as informações contidas nas componentes principais.

A Principal diferença entre PCA e SVD

- No entanto, é possível substituir a etapa 4 pela aplicação do SVD, uma vez que os k primeiros autovetores da matriz de covariância são as k dimensões de maior variabilidade. Neste sentido, podemos interpretar o PCA como o processo de fatoração do SVD, aplicado à matriz de covariância.
 - ▶ Assim, salvo as devidas diferenças teóricas, a questão prática se reduz à identificarmos as diferenças entre SVD sobre a matriz de covariância e SVD sobre a matriz original.

Definimos então a i -ésima imagem como $\mathbf{a}_i \in \mathbb{R}^{mn}$ tal que $1 \leq i \leq q$, onde q é o número de imagens no banco de dados. A partir delas, é criada a matriz que contém todas as imagens originais, $\mathbf{A} \in \mathbb{R}^{mn \times q}$.

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_1 \quad \dots \quad \mathbf{a}_q]$$

Face média:

$$\mathbf{f}_\mu = \frac{1}{q} \sum_{i=1}^q \mathbf{a}_i$$

Eigenfaces

Face média



(a) Corpo docente da EMap.



(b) FEI Face Database.

Figura: Face média

Cálculo da matriz de covariância

Em seguida, definimos a matriz com os dados centralizados M por:

$$m_i = \sum_{i=1}^q a_i - f_\mu$$

$$M = \begin{bmatrix} | & | & \dots & | \\ m_1 & m_2 & \dots & m_q \\ | & | & \dots & | \end{bmatrix}$$

A matriz de covariância amostral do nosso conjunto de dados, denotada por $C \in \mathbb{R}^{mn \times mn}$ pode ser calculada da seguinte maneira:

$$C = \frac{1}{q-1} \sum_{i=1}^q (a_i - f_\mu)(a_i - f_\mu)^T = \frac{1}{q-1} MM^T$$

Eigenfaces

Correção pela média




Figura: Imagens corrigidas pela média

Observe que C é simétrica e positiva definida, portanto, aplica-se o teorema espectral. A decomposição da matriz de covariância C usando a SVD é dada por:

$$C = U\Sigma V^T = U\Sigma U^T$$

onde U é a matriz de autovetores e Σ é uma matriz diagonal contendo os autovalores em ordem decrescente. Os autovetores em U são chamados de "eigenfaces". Eles representam as principais componentes de variação nas imagens faciais.

Eigenfaces

Eigenfaces mais relevantes




Figura: Eigenfaces mais relevantes de cada matriz

Eigenfaces

Eigenfaces menos relevantes




Figura: Eigenfaces menos relevantes de cada matriz

Para reconhecer um rosto novo, é necessário projetar a imagem desse rosto nas eigenfaces para obter os coeficientes de projeção. Seja \mathbf{z} o vetor de coeficientes de projeção de uma imagem de teste. Podemos calcular \mathbf{z} da seguinte maneira:

$$\mathbf{z} = \mathbf{U}^T (\mathbf{x}_{teste} - \mathbf{F}_\mu)$$

onde \mathbf{x}_{teste} é o vetor de pixels da imagem de teste.

Discussão dos Resultados

Reconstrução de Imagens

Suponha que queremos reconstruir a seguinte imagem:



Figura: Imagem a ser reconstruída

Discussão dos Resultados

Reconstrução de Imagens

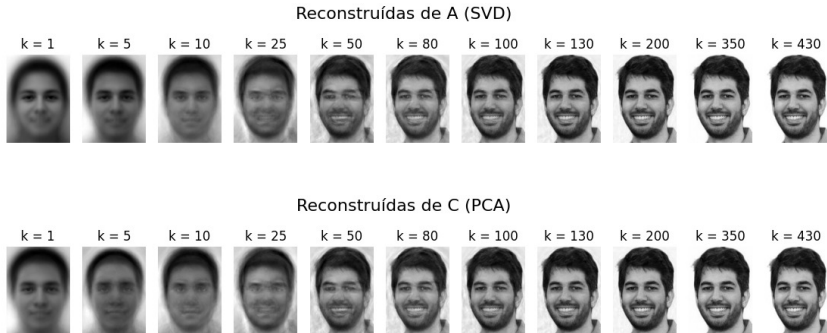


Figura: Imagem reconstruída

Discussão dos Resultados

Relevância das eigenfaces

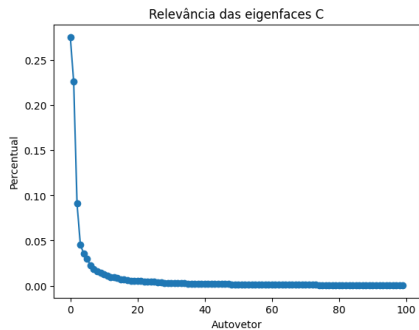



Figura: Relevância das Eigenfaces de cada matriz

A ocupa 76,8 mb = 0,1 gb
M ocupa 76,8 mb = 0,1 gb
C ocupa 4.177,6 mb = 4,1 gb
U_A_k100 ocupa 17,9 mb = 0,0 gb
coef_A ocupa 1,4 mb = 0,0 gb

Figura: Memória ocupada por cada matriz

Obrigado!